

# MODELOS SEMI ESTRUCTURALES PARA EL CRÉDITO AL CONSUMO

Luis Ortiz-Cevallos

2023-03-31



# Contents

<b>1</b>	<b>Aplicación para Guatemala</b>	<b>5</b>
1.1	Blanchard-Quah ortogonalización (restricciones) sobre $C(1)$ . . .	5



# Chapter 1

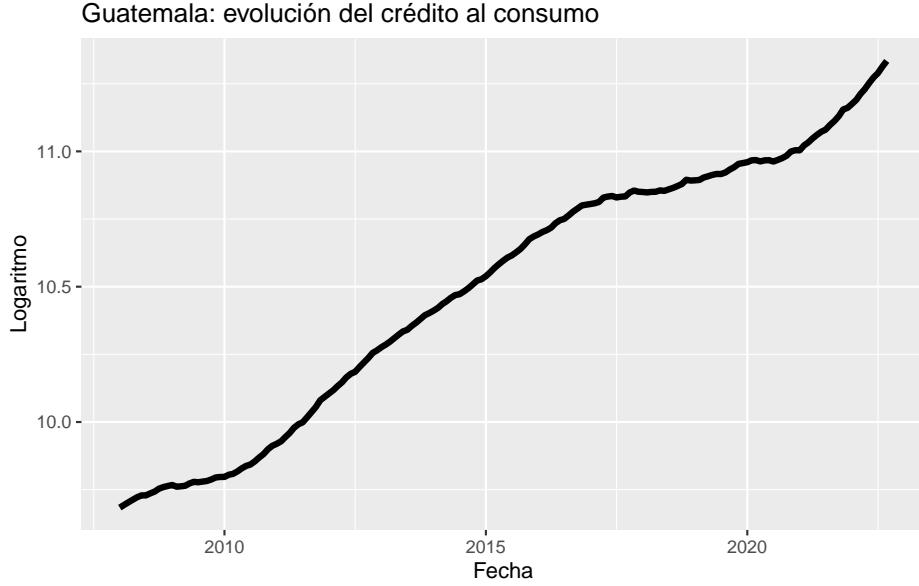
## Aplicación para Guatemala

### 1.1 Blanchard-Quah ortogonalización (restricciones) sobre $C(1)$

Al observar la evolución del crédito hacia consumo provisto por el sistema bancario guatemalteco y disponible en Secretaría Ejecutiva del Consejo Monetario Centroamericano (2023), se observa una series con una tendendencia estocástica.

```
library("zoo")
library("xts")
library(dplyr)
library(ggplot2)
library(kableExtra)
library(xtable)
library(tidyr)
library(quantmod)
library(RColorBrewer)
library(gridExtra)
#CARGAMOS DATOS MENSUALES
DATA_MES<-as.xts(read.zoo("GT_MES.csv", index.column = 1,
                        sep = ";", header=TRUE, format = "%Y-%m-%d"))
CREDITO<-DATA_MES$CRED
CREDITO<-data.frame(date=index(CREDITO), coredata(CREDITO))
CREDITO<-filter(CREDITO, date >= "2008-01-01")
colnames(CREDITO)<-c("date", "CREDITO")
CREDITO<-mutate(CREDITO, CONSUMO=log(CREDITO))
G<-ggplot(CREDITO, aes(x=date, y=CONSUMO))
G<-G+labs(y="Logaritmo",
          x="Fecha", title = "Guatemala: evolución del crédito al consumo",
          caption = "https://www.secmca.org/wp-content/uploads/2023/03/REPORTE_INDICADO")
```

```
RES_BANCARIOS_MARZO_2023.xlsx")+  
geom_line(size=1.5)  
G
```



[https://www.secmca.org/wp-content/uploads/2023/03/REPORTE\\_INDICADO\\_RES\\_BANCARIOS\\_MARZO\\_2023.xlsx](https://www.secmca.org/wp-content/uploads/2023/03/REPORTE_INDICADO_RES_BANCARIOS_MARZO_2023.xlsx)

El proceso de generación de la serie del crédito al consumo puede explicarse a través de la identificación de diferentes innovaciones. Una de ellas, las llamaré tecnológicas (en general uso ese término para referir los factores que pueden producir una mayor inclusión financiera independientemente si es producto de políticas o nuevas tecnologías), la segunda las de demanda y la tercera de absorción fiscal.

Para este ejercicio de identificación sigo la metodología propuesta por Blanchard and Quah (1988) y estimo la forma reducida de un Vector Autorregresivo integrado por la tasa de crecimiento de la cartera de consumo nominal ( $\Delta c_t$ ), la tasa de crecimiento del PIB ( $\Delta y_t$ ) y el porcentaje de los activos de los sistemas bancarios en títulos y valores públicos ( $\Delta x_t$ ). La representación de este VAR como un proceso de media móviles está dado por:

$$X_t = \begin{pmatrix} \Delta c_t \\ \Delta y_t \\ \Delta x_t \end{pmatrix} = A(L)e_t \quad (1.1)$$

Considero  $A(0) = I$  y  $\Sigma_e = E(ee^T)$  como la matriz de varianza y covarianza de la forma reducida del VAR mostrado en 1.1. Y supongo, primero que el crédito hacia consumo, la actividad económica y la exposición del sistema bancario

### 1.1. BLANCHARD-QUAH ORTOGONALIZACIÓN (RESTRICCIONES) SOBRE C(1)7

hacia valores del gobierno son producidos a través de tres procesos estructurales independientes con shocks de varianza unitaria. Y segundo, que uno de esos procesos, el de las innovaciones tecnológicas, es el responsable de la tendencia estocástica observada en el crédito para consumo. Con base en lo anterior defino un VAR estructural cuya representación como un proceso de medias móviles es el siguiente:

$$X_t = C(L)\epsilon_t = \begin{pmatrix} C_{1,1}(L) & C_{1,2}(L) & C_{1,3}(L) \\ C_{2,1}(L) & C_{2,2}(L) & C_{2,3}(L) \\ C_{3,1}(L) & C_{3,2}(L) & C_{3,3}(L) \end{pmatrix} \epsilon_t \quad (1.2)$$

Siendo  $\Sigma_\epsilon = E(\epsilon\epsilon^\tau) = I$  la matriz de varianza y covarianza de los shocks estructurales, los cuales son independientes y con varianza unitaria, y  $C_{1,2}(1) = C_{1,3}(1) = 0$ , indicando que el shock de demanda y fiscal sobre las variables tasa de crecimiento del PIB y porcentaje de activos invertidos en valores soberanos, en su orden, no tienen efectos de largo plazo en el crédito nominal para consumo.

El proceso y resultado de la estimación es el siguiente:

```
CRED      <-DATA_MES$CRED
FISCAL     <-DATA_MES$PUB
CRED       <-CRED["2008-01-01/2022-09-01"]
ep1        <-endpoints(CRED , on = "quarters")
CRED       <-period.apply(CRED , INDEX = ep1, FUN = sum)
DCRED      <-diff(100*log(CRED ), lag=4)
FISCAL     <-FISCAL["2008-01-01/2022-09-01"]
ep2        <-endpoints(FISCAL , on = "quarters")
TASA       <-period.apply(FISCAL, INDEX = ep2, FUN = max)
DATA_TRIM  <-as.xts(read.zoo("TRIM_GT.csv", index.column = 1,
                           sep = ";", header=TRUE, format = "%Y-%m-%d"))
PIB        <-DATA_TRIM$PIB
PIB        <-PIB["2001-03-01/2022-09-01"]
DPIB       <-diff(100*log(PIB), lag=4)
#COMBINAR
BASE       <-merge(DCRED, DPIB,join="left")
BASE       <-merge(BASE, FISCAL,join="left")
BASE       <-data.frame(date=index(BASE), coredata(BASE))
colnames(BASE)<-c("date","c", "y", 'x')
DATA       <-dplyr::select(BASE, date, c,y,x)
colnames(DATA)<-c("date", "c", "y", 'x')
DATA       <-filter(DATA, date >= "2016-03-01")
DATA       <-xts(DATA[, -1], order.by=as.Date(DATA[,1], "%Y/%m/%d"))
library("svars")
VAR        <- vars::VAR(DATA[,c(1,2,3)],p =2,type = "const")
VAR$varresult$c$c$coefficients
```

##	c.11	y.11	x.11	c.12	y.12	x.12
----	------	------	------	------	------	------

```
## 1.12127681 0.15372782 0.29159136 -0.11201301 -0.01109658 0.18036079
##          const
## -9.91395632
```

```
VAR$varresult$y$coefficients
```

```
##          c.l1          y.l1          x.l1          c.l2          y.l2          x.l2
## -0.25412909 0.57678412 0.39960337 0.27004423 -0.15357170 -0.02784201
##          const
## -5.84527946
```

```
VAR$varresult$x$coefficients
```

```
##          c.l1          y.l1          x.l1          c.l2          y.l2          x.l2
## 0.18016081 -0.13225215 0.28849915 -0.26998876 -0.03531496 0.45762387
##          const
## 6.70493277
```

```
SIGMA<-summary(VAR)
```

```
SIGMA$covres
```

```
##          c          y          x
## c 1.2422579 2.067672 0.1369263
## y 2.0676722 13.450295 0.5679060
## x 0.1369263 0.567906 1.6557099
```

Habiendo estimado el VAR a continuación encontramos las restricciones de corto o contemporáneas y largo plazo:

```
BQMODEL<- BQ(VAR)
```

```
summary(BQMODEL)
```

```
##
## SVAR Estimation Results:
## =====
##
## Call:
## BQ(x = VAR)
##
## Type: Blanchard-Quah
## Sample size: 25
## Log Likelihood: -144.025
##
## Estimated contemporaneous impact matrix:
##          c          y          x
## c 0.45904 0.3686 -0.9464
## y 0.08455 3.5899 -0.7455
## x 1.15782 0.2366 0.5091
##
```



### 1.1. BLANCHARD-QUAH ORTOGONALIZACIÓN (RESTRICCIONES) SOBRE C(1)9

```
## Estimated identified long run impact matrix:
##           c           y           x
## c 16.7627  0.000 0.000
## y -0.1924  4.788 0.000
## x -1.2435 -2.228 2.005
##
## Covariance matrix of reduced form residuals (*100):
##           c           y           x
## c 124.23  206.77  13.69
## y 206.77 1345.03  56.79
## x  13.69   56.79 165.57
```

En seguida, calculamos la función impulso respuesta para cada variable, teniendo en cuenta que el PIB y la proporción de activos del sistema bancario invertidos en títulos y valores del gobierno no sufren en el largo plazo ningún efecto de los tres shocks estructurales.

```
FIR_BQ <- irf(BQMODEL,n.ahead = 32, impulse = c( "c", "y", "x"), boot =FALSE)
tecno  <- cbind(cumsum(FIR_BQ$irf$c[, 1]), FIR_BQ$irf$c[, 2], FIR_BQ$irf$c[, 3])
RESULTADO1<-as.data.frame(tecno)
PERIODO<-seq(1,33,1)
RESULTADO1 <-cbind(RESULTADO1,PERIODO)
CODE<-rep("Tecnológico",33)
RESULTADO1 <-cbind(RESULTADO1,CODE)
#####
demanda <- cbind(FIR_BQ$irf$y[, 1], FIR_BQ$irf$y[, 2], FIR_BQ$irf$y[, 3])
RESULTADO2<-as.data.frame(demanda)
RESULTADO2 <-cbind(RESULTADO2,PERIODO)
CODE<-rep("Demanda",33)
RESULTADO2 <-cbind(RESULTADO2,CODE)
#####
fiscal <- cbind(-1*FIR_BQ$irf$x[, 1], -1*FIR_BQ$irf$x[, 2], -1*FIR_BQ$irf$x[, 3])
RESULTADO3 <-as.data.frame(fiscal)
RESULTADO3 <-cbind(RESULTADO3,PERIODO)
CODE<-rep("Fiscal",33)
RESULTADO3<-cbind(RESULTADO3,CODE)
RESULTADO <-rbind(RESULTADO1,RESULTADO2,RESULTADO3)
BASE_LONG <- gather(RESULTADO, key="measure", value="value",c("V1", "V2", "V3"))
BASE_LONG$measure <- factor(BASE_LONG$measure,levels = ,c("V1", "V2", "V3"))
BASE_LONG$CODE <- factor(BASE_LONG$CODE,levels = c("Tecnológico", "Demanda", "Fiscal"))

variable_names <- list(
  "Tecnológico" = "Shock tecnológicos",
  "Demanda" = "Shock de demanda",
  "Fiscal" = "Shock fiscal"
)
```

```

variable_labeller2 <- function(variable,value){
  if (variable=='CODE') {
    return(variable_names[value])
  } else {
    return(region_names)
  }
}
paleta<-c("blue","red", "burlywood")
Z<-ggplot(BASE_LONG, aes(x=PERIODO, y=value, group = measure,
                        colour=measure))+
  facet_wrap(~CODE, scales="free", labeller= variable_labeller2)
Z<-Z+labs(y="Respuesta (%)",
          x="Períodos (trimestres)", title = "Guatemala: funciones impulso respuestas"
          caption = "Elaboración propia con base en: https://www.secmca.org/wp-content
RES_BANCARIOS_MARZO_2023.xlsx")+
  geom_hline(yintercept=0, linetype="dashed",
            color = "black", size=1)+
  geom_line(size=1.5)+
  scale_color_manual(values=paleta,
                    labels = c("Crédito para consumo",
                              "Producto",
                              "Proporción de los activos invertidos en valores públi
                              ))
Z<-Z+theme(axis.line.x = element_line(colour = "black", size = 0.5),
          axis.line.y.left = element_line(colour = "black", size = 0.5),
          axis.line.y.right = element_blank(),
          axis.text.x = element_text( color = "black", size = 14),
          axis.text.y = element_text( color = "black", size = 14),
          axis.title.x = element_text( color = "black", size = 15),
          axis.title.y = element_text( color = "black", size = 15),
          panel.grid.minor = element_blank(),
          panel.grid.major.y = element_blank(),
          panel.grid.major.x = element_blank(),
          panel.border = element_blank(),
          panel.background = element_blank(),
          legend.key=element_rect(fill = "white", colour = "white",
                                color = "white", inherit.blank = FALSE),
          legend.title = element_blank(),
          legend.text = element_text(size=18),
          legend.position="bottom",
          legend.spacing.x = unit(0.10, 'cm'),
          legend.margin=margin(),
          legend.background = element_rect(fill = "white", colour = "transparent",
                                           color = "white", inherit.blank = FALSE),
          strip.text.x = element_text(


```

## 1.1. BLANCHARD-QUAH ORTOGONALIZACIÓN (RESTRICCIONES) SOBRE C(1)11

```

        size = 20, color = "black", face = "bold.italic"
    )
)+guides(color = guide_legend(nrow = 1))+
  scale_x_continuous(breaks=seq(0,32,4))
Z

```



consumo — Producto — Proporción de los activos invertidos

Elaboración propia con base en: [https://www.secmca.org/wp-content/uploads/2023/03/REPORTE\\_INDICADO\\_RES\\_BANCARIOS\\_MARZO\\_2023.xlsx](https://www.secmca.org/wp-content/uploads/2023/03/REPORTE_INDICADO_RES_BANCARIOS_MARZO_2023.xlsx)

### Implicaciones

*#Descomposición de la varianza HISTÓRICA*

*##FUNCIONES*

```
VARhd <- function(Estimation){
```

```
  ## make X and Y
```

```
  nlag <- Estimation$p # number of lags
```

```
  DATA <- Estimation$y # data
```

```
  QQ <- VARmakexy(DATA,nlag,1)
```

```
  #invA <- t(chol(as.matrix(summary(Estimation)$covres)))# inverse of the A matrix
```

```
  invA <- BQMODEL$LRIM
```

```
  #invA <- bqfactor
```

```
  Fcomp <- companionmatrix(Estimation)
```

```
# Companion matrix
```

```
  #det <- c_case
```

```
# constant and/or trends
```

```
  F1 <- t(QQ$Ft)
```

```
# make comparable to notes
```

```
  eps <- ginv(invA) %*% t(residuals(Estimation))
```

```
  # structural errors
```

```
  nvar <- Estimation$K
```

```
# number of endogenous variables
```

```
  nvarXeq <- nvar * nlag
```

```
# number of lagged endogenous per equation
```

```
  nvar_ex <- 0
```

```
# number of exogenous (excluding constant)
```

```

Y      <- QQ$Y                                     # left-hand side
#X     <- QQ$X[, (1+det):(nvarXeq+det)]             # right-hand side (no exog
nobs   <- nrow(Y)                                   # number of observations

## Compute historical decompositions
# Contribution of each shock
invA_big <- matrix(0, nvarXeq, nvar)
invA_big[1:nvar,] <- invA
Icomp    <- cbind(diag(nvar), matrix(0, nvar, (nlag-1)*nvar))
HDshock_big <- array(0, dim=c(nlag*nvar, nobs+1, nvar))
HDshock    <- array(0, dim=c(nvar, (nobs+1), nvar))

for (j in 1:nvar){ # for each variable
  eps_big <- matrix(0, nvar, (nobs+1)) # matrix of shocks conformable with companion
  eps_big[j, 2:ncol(eps_big)] <- eps[j,]
  for (i in 2:(nobs+1)){
    HDshock_big[, i, j] <- invA_big %*% eps_big[, i] + Fcomp %*% HDshock_big[, (i-1), j]
    HDshock[, i, j] <- Icomp %*% HDshock_big[, i, j]
  }
}

HD.shock <- array(0, dim=c((nobs+nlag), nvar, nvar)) # [nobs x shock x var]

for (i in 1:nvar){
  for (j in 1:nvar){
    HD.shock[, j, i] <- c(rep(NA, nlag), HDshock[i, (2:dim(HDshock)[2]), j])
  }
}

return(HD.shock)
}

#####
VARmakexy <- function(DATA, lags, c_case){
  nobs <- nrow(DATA)
  #Y matrix
  Y <- DATA[(lags+1):nrow(DATA),]
  Y <- DATA[-c(1:lags),]
  #X-matrix
  if (c_case==0){
    X <- NA
    for (jj in 0:(lags-1)){
      X <- rbind(DATA[(jj+1):(nobs-lags+jj),])
    }
  } else if (c_case==1){ #constant
    X <- NA

```

### 1.1. BLANCHARD-QUAH ORTOGONALIZACIÓN (RESTRICCIONES) SOBRE $C(1)$ <sup>13</sup>

```
for (jj in 0:(lags-1)){
  X <- rbind(DATA[(jj+1):(nobs-lags+jj),])
}
X <- cbind(matrix(1,(nobs-lags),1), X)
} else if(c_case==2){ # time trend and constant
  X <- NA
  for (jj in 0:(lags-1)){
    X <- rbind(DATA[(jj+1):(nobs-lags+jj),])
  }
  trend <- c(1:nrow(X))
  X <- cbind(matrix(1,(nobs-lags),1), t(trend))
}
A <- (t(X) %*% as.matrix(X))
B <- (as.matrix(t(X)) %*% as.matrix(Y))

Ft <- ginv(A) %*% B
retu <- list(X=X,Y=Y, Ft=Ft)
return(retu)
}

companionmatrix <- function (x)
{
  if (!(class(x) == "varest")) {
    stop("\nPlease provide an object of class 'varest', generated by 'VAR()'.\n")
  }
  K <- x$K
  p <- x$p
  A <- unlist(Acoef(x))
  companion <- matrix(0, nrow = K * p, ncol = K * p)
  companion[1:K, 1:(K * p)] <- A
  if (p > 1) {
    j <- 0
    for (i in (K + 1):(K * p)) {
      j <- j + 1
      companion[i, j] <- 1
    }
  }
  return(companion)
}

SERIE <- fitted(VAR)
BQh <- VARhd(VAR)
dates1 <- seq(as.Date("2016-03-01"), length=length(SERIE[,1])+2, by="quarters")
BQc_T <- BQh[,1,1] #SHOCK TECNOLÓGICO SOBRE c
BQc_T <- xts(BQc_T, order.by=dates1)
```

```
BQc_D<-BQh[,1,2] #SHOCK DEMANDA SOBRE c  
BQc_D<-xts(BQc_D, order.by=dates1)  
BQc_F<-BQh[,1,3] #SHOCK DEMANDA2 SOBRE c  
BQc_F<-xts(BQc_F, order.by=dates1)
```

# Bibliography

Blanchard, O. J. and Quah, D. (1988). The Dynamic Effects of Aggregate Demand and Supply Disturbances. NBER Working Papers 2737, National Bureau of Economic Research, Inc.

Secretaría Ejecutiva del Consejo Monetario Centroamericano (2023). INDICADORES BANCARIOS. [https://www.secmca.org/wp-content/uploads/2023/03/REPORTE\\_INDICADORES\\_BANCARIOS\\_MARZO\\_2023.xlsx](https://www.secmca.org/wp-content/uploads/2023/03/REPORTE_INDICADORES_BANCARIOS_MARZO_2023.xlsx). Accesado: 2023-03-30.